1) датасет: CORD-19, взяты названия и абстракты статей как корпус из файла metadata.csv https://www.kaggle.com/datasets/allen-institute-for-ai/CORD-19-research-challenge?select=metadata.csv
взяты 100 случайных статей, объединенных в 'название статьи' + '. ' + 'абстракт'

2) Гипотеза 1: overlap в chunking
Режем текст по 50 слов. Без overlap получилось 507 кусков, с 20% overlap — 593 куска. Разница в памяти копеечная (всего 86 лишних кусков), а польза огромная: Recall@3 вырос с 50% до 90%.

Overlap помог в вопросе 2, в исходном тексте статьи на 50-м слове как раз находилась фраза "...by the World Health Organization". При нарезке без overlap текст резался ровно посередине: первый кусок заканчивался на слове "...World", а второй начинался со слова "Organization...". Ни один из этих кусков по отдельности не содержал полного названия организации, поэтому векторный поиск не понял, что тут есть ответ, и выдал 0%. А вот при нарезке с overlap конец второго куска скопировался в конец первого, и в базе появился кусок, где вся фраза «World Health Organization» была целая

Overlap не понадобился в вопросе 8, здесь искомая фраза «cerebrospinal fluid» находилась примерно в середине предложения, далеко от 50-го и 100-го слов. Из-за этого она целиком и без потерь попала в один кусок как при нарезке без overlap, так и с overlap. Векторный поиск без проблем нашел смысловой ответ в обеих базах. В этом случае overlap никак не повлиял на результат, потому что граница чанка не разорвала нужный нам факт.

3) Гипотеза 2: semantic chunking
Здесь мы резали тексты по смыслу, получилось 330 семантиков. Recall@3 составил 80%. Это лучше, чем просто резать без overlap (50%), но хуже, чем с overlap (90%). Overlap сработал лучше, потому что абстракты плотно набиты информацией, каждое предложение - отдельный смысл, а слишком маленькие куски в семантике плохо работают, но лучше, чем без overlap

4) Гипотеза 3: hybrid search

Трудные: Dense=40%, BM25=60%, Hybrid=60%
Обычные: Dense=60%, BM25=80%, Hybrid=60%
Гибрид справился не так хорошо: в научных статьях ответы почти всегда содержат точные слова из вопроса. Векторный поиск пытался искать смысл и тащил в выдачу похожие по смыслу, но не точные куски. В Hybrid этот шум от Dense понижал ранги идеальных ответов от BM25. Поэтому в научных текстах лучше использовать просто BM25

5) Гипотеза 4: влияние размера top-k (Вариант B)
k=1: Полезного 40%, мусора 60%
k=3: Полезного 17%, мусора 83%
k=10: Полезного 7%, мусора 93%
Гипотеза «больше контекста — не всегда лучше» подтвердилась железно. При увеличении k мы не даем модели больше ответов, мы просто заливаем ее излишним контекстом. Полезность падает, поэтому не нужно давать много, нужно лишь самое необходимое

6) Общий вывод

Из всего проверенного на корпусе ковидных статей реально работает базовое: overlap в чанкинге (чтобы не рвать слова) и небольшой размер top-k (чтобы не зашумлять промпт). Семантический чанкинг для коротких текстов избыточен, а гибридный поиск сливает обычному BM25, потому что в научке точные слова важнее смысла.